

INFORME FINAL

Análisis de Comportamiento y Reducción de Dimensionalidad en Usuarios de Streaming

1. Contexto y Objetivos

El mercado global de streaming exige optimizar retención y personalización. Este proyecto analiza el comportamiento de una base internacional de clientes para construir un ciclo analítico robusto, reproducible y metodológicamente justificado. Los objetivos estratégicos son: mitigar anomalías de calidad en el registro original; identificar patrones sociodemográficos y de consumo (minutos mensuales) según plan y geografía; aplicar escalamiento estadístico y Análisis de Componentes Principales (PCA) para diagnosticar la estructura subyacente de la actividad del usuario y evaluar la factibilidad de reducción dimensional.

2. Dataset y Calidad Inicial

El dataset original (streaming_users_dirty.json) contenía 8.160 registros y 8 variables mixtas (demográficas: age, country; transaccionales: subscription_plan, last_login_date; operativas: monthly_watch_time_mins, favorite_genre, customer_support_tickets). La auditoría inicial reveló severos problemas: registros duplicados con mismo user_id, valores nulos ocultos bajo etiquetas de texto o celdas vacías, inconsistencias de formato (mayúsculas/minúsculas/tildes), fechas corruptas ('not_available') y edades biológicamente imposibles (negativas o >120 años).

3. Decisiones de Limpieza y Preparación

Se diseñó un pipeline secuencial documentado en pipeline_log.csv para garantizar trazabilidad sin alterar el original. Las acciones fueron:

- **Saneamiento y duplicados:** se eliminaron 128 registros duplicados y se estandarizaron textos a minúsculas sin caracteres especiales.
- **Filtro temporal:** se removieron 399 filas con fechas corruptas o fuera del rango lógico (2018-2025), consolidando un volumen final de 7.633 usuarios (**tasa de retención neta del 93,54%**).
- **Imputación de faltantes:** favorite_genre (MCAR, ~3%) se imputó como 'No especificado'. monthly_watch_time_mins (MAR, sesgado por plan: 9,68% ausentes en Premium vs. 0,12% en Básico) se imputó con la mediana segmentada por plan.
- **Suavizado de outliers:** edades extremas se corrigieron con la mediana global. Para consumo y tickets se aplicó clipping estadístico con límite en $3,0 \times \text{IQR}$.

4. Hallazgos del Análisis Exploratorio (EDA)

El EDA reveló patrones de alto valor estratégico:

- **Distribución demográfica y preferencias:** la edad presenta una curva simétrica concentrada en adultos jóvenes (25-45 años, moda 30-35). Los géneros están distribuidos homogéneamente, con 'Comedia' como líder marginal, lo que exige un catálogo diversificado.
- **Impacto del plan de suscripción:** la mediana de minutos mensuales crece linealmente con el plan (Básico < Estándar < Premium), validando que los usuarios de mayor valor transaccional son los consumidores más intensivos.

- **Asimetría regional en soporte técnico:** se observaron interacciones cruzadas por país. En Chile y Perú, los usuarios Premium lideran el promedio de tickets; en Brasil y México, el mismo segmento es el que menos reclama; en Argentina, los Estándar encabezan los reclamos. Esto demuestra que la fricción operativa tiene raíz localizada, impidiendo políticas de atención genéricas.

5. Análisis de Componentes Principales (PCA)

Previo al PCA, las variables numéricas (age, monthly_watch_time_mins, customer_support_tickets) se normalizaron con Z-score (media ~0, varianza ~1). El Scree Plot mostró varianzas explicadas casi idénticas: **PC1 = 33,79%, PC2 = 33,12%, PC3 = 33,09%**. Al estar la variabilidad distribuida equitativamente, prescindir de una componente implicaría perder un tercio de la información; por tanto, se retuvo el 100% de las componentes (varianza acumulada = 100%). Si bien no hubo reducción dimensional, la matriz de cargas (loadings) permitió definir tres perfiles ortogonales y mutuamente excluyentes:

1. **PC1 – Actividad General del Usuario** (edad 0,58; minutos 0,59; tickets 0,57): eje de intensidad global que agrupa a usuarios de mayor edad, alto consumo y más reclamos.
2. **PC2 – Fricción en Usuarios Jóvenes** (edad -0,60; minutos -0,17; tickets 0,78): polaridad inversa entre edad y reclamos; sintetiza a clientes jóvenes con alta tasa de quejas, independiente del tiempo de visualización.
3. **PC3 – Consumo Intensivo Silencioso** (edad -0,56; minutos 0,79; tickets -0,25): dominado por alto peso en minutos y cargas negativas en soporte y edad; define a jóvenes enfocados en consumo puro, sin interacción con atención técnica.

6. Conclusiones y Limitaciones

Conclusiones generales: se consolidó un pipeline reproducible con retención neta del 93,54%, eliminando el ruido inicial. Se demostró que el plan Premium tracciona el mayor consumo, pero genera fricciones de soporte asimétricas según país. Estructuralmente, PCA evidenció que las dimensiones del comportamiento están balanceadas, requiriendo conservar los tres ejes, pero permitiendo definir tres perfiles sintéticos claros (actividad general, jóvenes reclamantes y consumidores silenciosos) ideales para futuras campañas automatizadas de fidelización.

Limitaciones identificadas: (1) la ausencia de correlación lineal fuerte entre métricas cuantitativas limitó la compresión del PCA, forzando a retener todas las dimensiones; (2) el clipping con $3,0 \times \text{IQR}$ pudo suavizar picos legítimos de consumo corporativo o fallas masivas; (3) el alcance es puramente diagnóstico-descriptivo, sin capacidades predictivas supervisadas (ej. modelos de churn).

Enlaces oficiales del proyecto:

- [Repositorio de GitHub](#)
- [App Streamlit](#)